인공지능 윤리

CONTENTS

01 인공지능의 신뢰성

02 인공지능의 편향성

03 인공지능의 악용 가능성

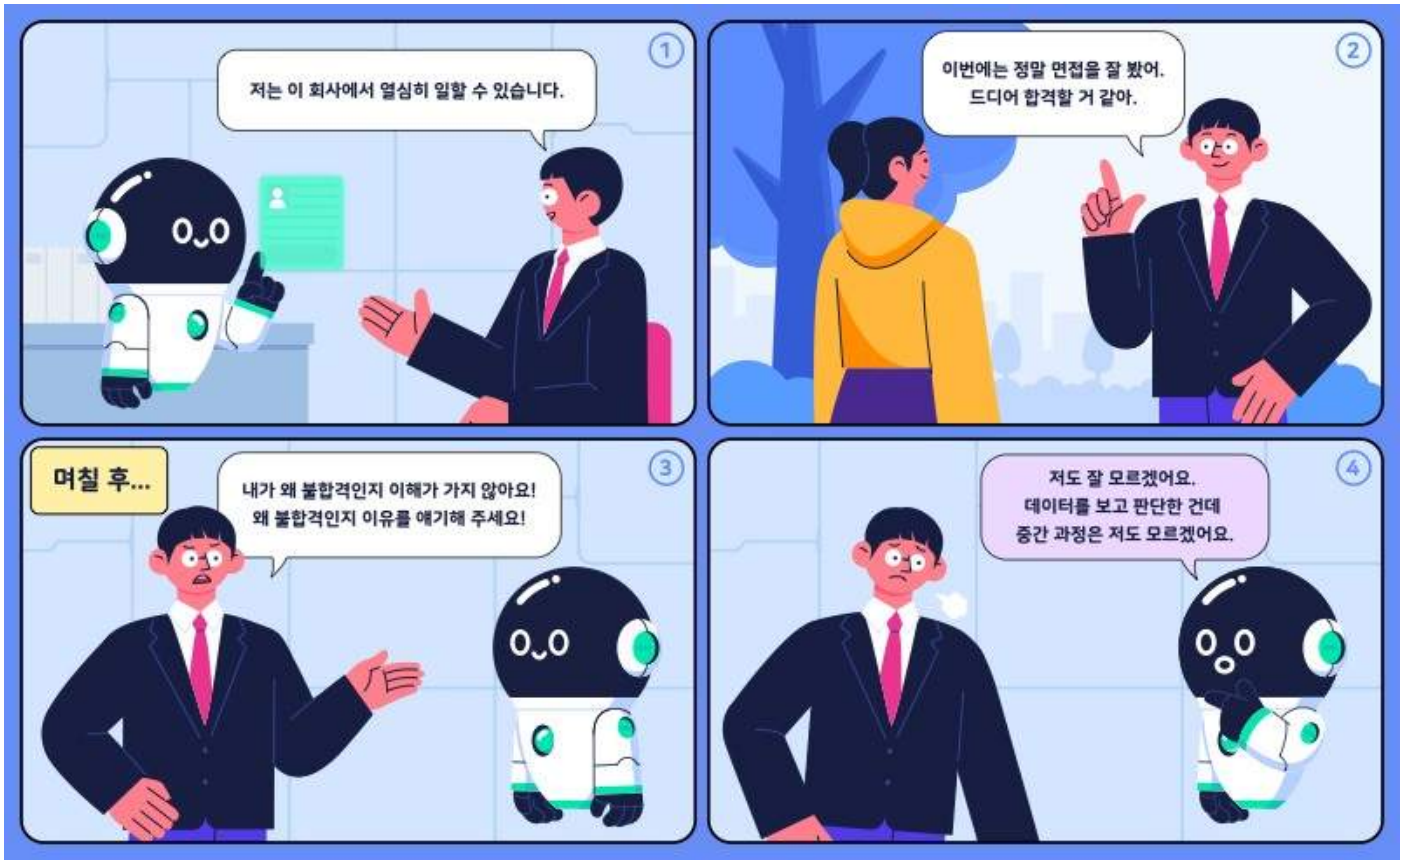
04 인공지능의 책임성

01 인공지능의 신뢰성

데이터 기반 인공지능과 신뢰성


1
2
이 강아지는 건강합니다.
다행이야!
1년 후..
3
건강하다고 했잖아요!
1년 전에 제대로 알았으면
이렇게까지 나빠지지 않았을 텐데!
4
저도 잘 모르겠어요.
데이터를 보고 판단한 건데
중간 과정은 저도 모르겠어요.
뭐라고요? 인공지능 의사는
완벽할줄 알았는데...

데이터 기반 인공지능


①
저는 이 회사에서 열심히 일할 수 있습니다.
②
이번에는 정말 면접을 잘 봤어.
드디어 합격할 거 같아.
며칠 후...
③
내가 왜 불합격인지 이해가 가지 않아요!
왜 불합격인지 이유를 얘기해 주세요!
④
저도 잘 모르겠어요.
데이터를 보고 판단한 건데
중간 과정은 저도 모르겠어요.

데이터 기반 인공지능


문제
OO이의 생일 선물을
뭘 사주면 좋을까?
평소에 OO이가 자주 쓰던
물건을 관찰
평소에 OO이가 자주 쓰던
물건에 대한 데이터
평소에 핸드크림을
자주 쓰니까
선물해줘야겠다.
핸드크림을
선물하는 것을
추천합니다.

1.1 인공지능에 사용되는 데이터

	A	B	C	D	E	F
1	일자	요일	시간대	업종	시도	시군구
2	20180601	금	00:00	음식점	서울특별시	강남구
3	20180601	금	00:00	음식점	서울특별시	강동구
4	20180601	금	00:00	음식점	서울특별시	강서구
5	20180601	금	00:00	음식점	서울특별시	동대문
6	20180601	금	00:00	음식점	서울특별시	서대문
7	20180601	금	00:00	음식점	서울특별시	서초구
8	20180601	금	00:00	음식점	서울특별시	성동구
9	20180601	금	00:00	음식점	서울특별시	송파구

정형 데이터



비정형 데이터

데이터 기반 인공지능

1.2 기계학습



데이터
이미지, 소리, 문자, 표 등

인공지능모델
분류, 회귀(예측) 등

웹페이지,
스마트폰 애플리케이션 등

인공지능 모델의 정확도

2.1 인공지능 모델의 정확도란

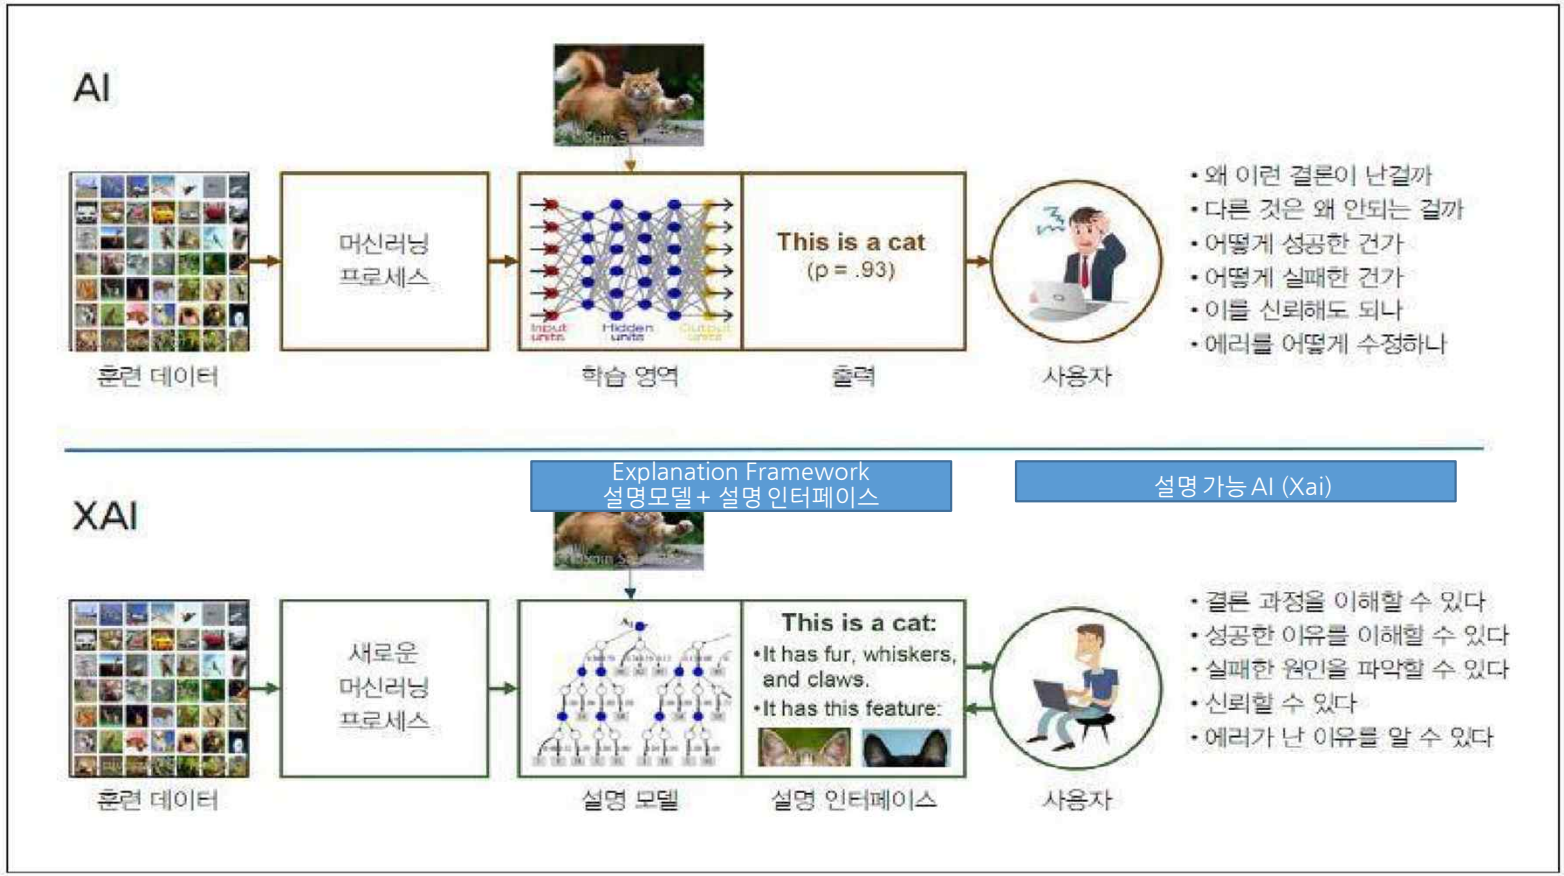
	인공지능 A	인공지능 B	실제 합격 결과
학생 1	합격	불합격	합격
학생 2	불합격	합격	불합격
학생 3	합격	합격	합격
학생 4	불합격	불합격	불합격

인공지능 모델의 정확도

2.2 학습 데이터와 테스트 데이터



참고 자료


AI
머신러닝
프로세스
This is a cat
(p = .93)
훈련 데이터
학습 영역
출력
사용자
• 왜 이런 결론이 난걸까
• 다른 것은 왜 안되는 걸까
• 어떻게 성공한 건가
• 어떻게 실패한 건가
• 이를 신뢰해도 되나
• 에러를 어떻게 수정하나
Explanation Framework
설명모델 + 설명 인터페이스
설명 가능 AI (Xai)
XAI
새로운
머신러닝
프로세스
This is a cat:
•It has fur, whiskers, and claws.
•It has this feature:
훈련 데이터
설명 모델
설명 인터페이스
사용자
• 결론 과정을 이해할 수 있다
• 성공한 이유를 이해할 수 있다
• 실패한 원인을 파악할 수 있다
• 신뢰할 수 있다
• 에러가 난 이유를 알 수 있다

01 인공지능의 신뢰성

인공지능의 신뢰성과 사회적 영향

인공지능의 신뢰성과 사회적 영향

1. 인공지능을 활용한 의사결정



인공지능의 신뢰성과 사회적 영향

1-1. 인공지능이 의사결정에 활용되는 사례 및 사회적 영향



인공지능의 신뢰성과 사회적 영향

(참고) 기업의 노력

네이버 AI 윤리 준칙

네이버는 첨단의 AI 기술을 누구나 쉽고 편리하게 활용할 수 있는 일상의 도구로 만들겠습니다. 사용자에게 새로운 연결의 경험을 선보이는 도전을 멈추지 않음으로써 다양한 기회와 가능성을 열어 나가겠습니다. 이를 위해 네이버의 모든 구성원은 AI 개발과 이용에 있어 아래와 같은 윤리 원칙을 준수하겠습니다.

1. 사람을 위한 AI 개발

네이버가 개발하고 이용하는 AI는 사람을 위한 일상의 도구입니다. 네이버는 AI의 개발과 이용에 있어 인간 중심의 가치를 최우선으로 삼겠습니다.

네이버는 사용자의 일상에 편리함을 더하기 위해 기술을 개발해왔고, AI 역시 일상의 도구로 활용될 수 있도록 발전시켜 나가고 있습니다. **네이버는 AI가 우리의 삶을 편리하게 만들어줄 수 있는 기술이지만, 세상의 다른 모든 것처럼 완벽할 수 없다는 점을 인식하고 있습니다.**

네이버는 AI가 사람을 위한 일상의 도구가 될 수 있도록, 지속적으로 살펴보며 개선해 나가겠습니다.

주제 마무리

이번 주제에서 배운 내용을 생각하며, 빈칸을 채워봅시다.

인공지능이 데이터를 분류하여 예측한 결과 중 정답을 맞힌 비율을 분류 인공지능 모델의 ( ) 라고 한다.

기계학습 모델을 훈련시킬 때는 학습 데이터를 사용하고, 모델의 성능을 평가할 때는 ( )를 사용한다.

인공지능을 개발하고 사용하는 데에는 인공지능을 ( )하는 사람, 인공지능 도입을 결정하거나 서비스를 제공하는 사람, 그리고 인공지능 서비스를 ( )하는 사람 등이 관련되어 있다.

주제 마무리

이번 주제에서 배운 내용을 생각하며, 빈칸을 채워봅시다.

인공지능이 데이터를 분류하여 예측한 결과 중 정답을 맞힌 비율을 분류 인공지능 모델의 (정확도) 라고 한다.

기계학습 모델을 훈련시킬 때는 학습 데이터를 사용하고, 모델의 성능을 평가할 때는 (테스트 데이터)를 사용한다.

인공지능을 개발하고 사용하는 데에는 인공지능을 (개발)하는 사람, 인공지능 도입을 결정하거나 서비스를 제공하는 사람, 그리고 인공지능 서비스를 (사용)하는 사람 등이 관련되어 있다.

02 인공지능의 편향성

데이터 편향성



출처 : https://youtu.be/4BDSDhnPglY

편향(Bias)과 편견(Prejudice/Vorurteil)

- 통계적, 기술적 용어와 윤리적 용어
- 호크하이머 (M. Horkheimer)
  - 고대 : 해롭지는 않은 사실인데, 이전의 경험과 결정에 근거한 판단
  - 근대 : 이성의 타율성에 기울어지는 경향 (합리주의) /

    사실을 통한 검증 이전의 견해 (경험론)
  - 궁극적인 최종 판결이 내려지기 전에 법적으로 미리 결정함

    → 근거. 지워지지 않는 판단

부정적 편견 vs 긍정적 편견

- 가디머 (Hans-Georg Gadamer) :
  - 합리주의적 사유와 비합리주의적 사유의 간극
    → 편견에 대한 부정적 인식 발생
  - 긍정적 편견 개념 주장

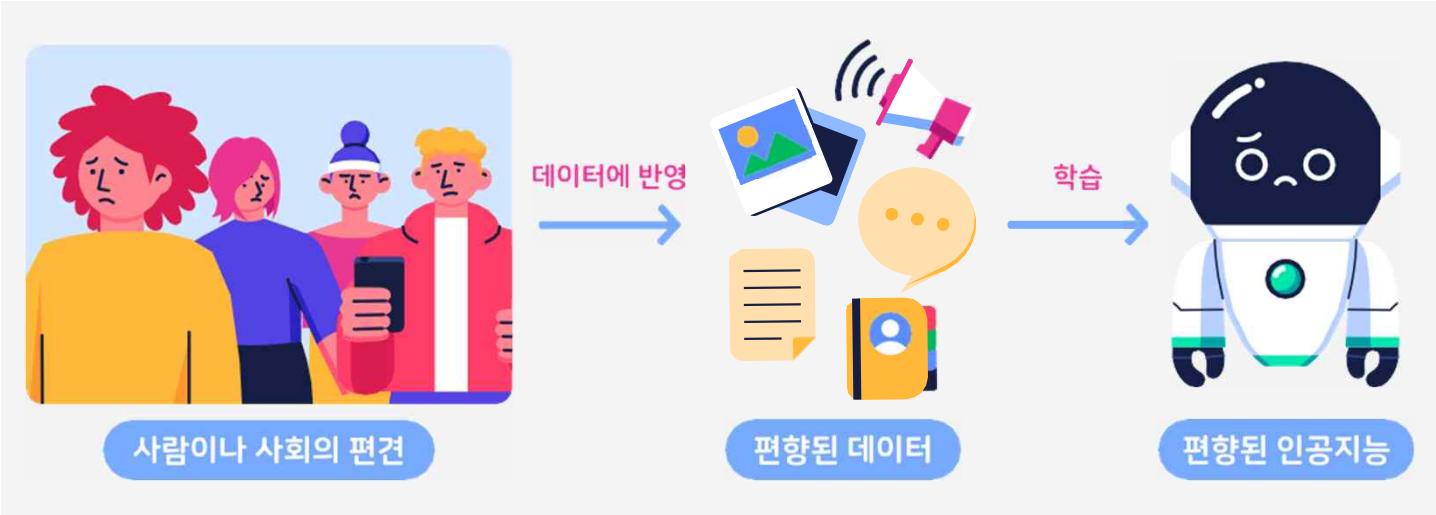
- 편견은 언제나 참다운 이해의 장애로 작용하고,
  그래서 제한되거나 제거되어야 하는가? 아니면 해석학적 생산성을 산출하는
  역사적 조건으로 인정되어야 하는가?

데이터 편향성


①
저는 범인이 아닙니다.
억울해요!
②
당신 말이 맞는지
인공지능에게
물어봐야겠어요.
③
이 사람은 범죄를 저지르지
않았을 것입니다.
금발머리이기 때문입니다.
④

데이터 편향성

1. 데이터 편향성이란



데이터 편향성

데이터 편향성이란?

1. 기계학습 모델을 학습시키는 데 사용되는 데이터가
사람이나 사회가 가지는 편견을 포함하고 있는 것을 의미

2. 편향성을 가진 데이터를 사용하여 학습한 인공지능은
편향된 결과를 출력할 수밖에 없고, 그 결과 어떤 종류의 차별을 가져오게 됨

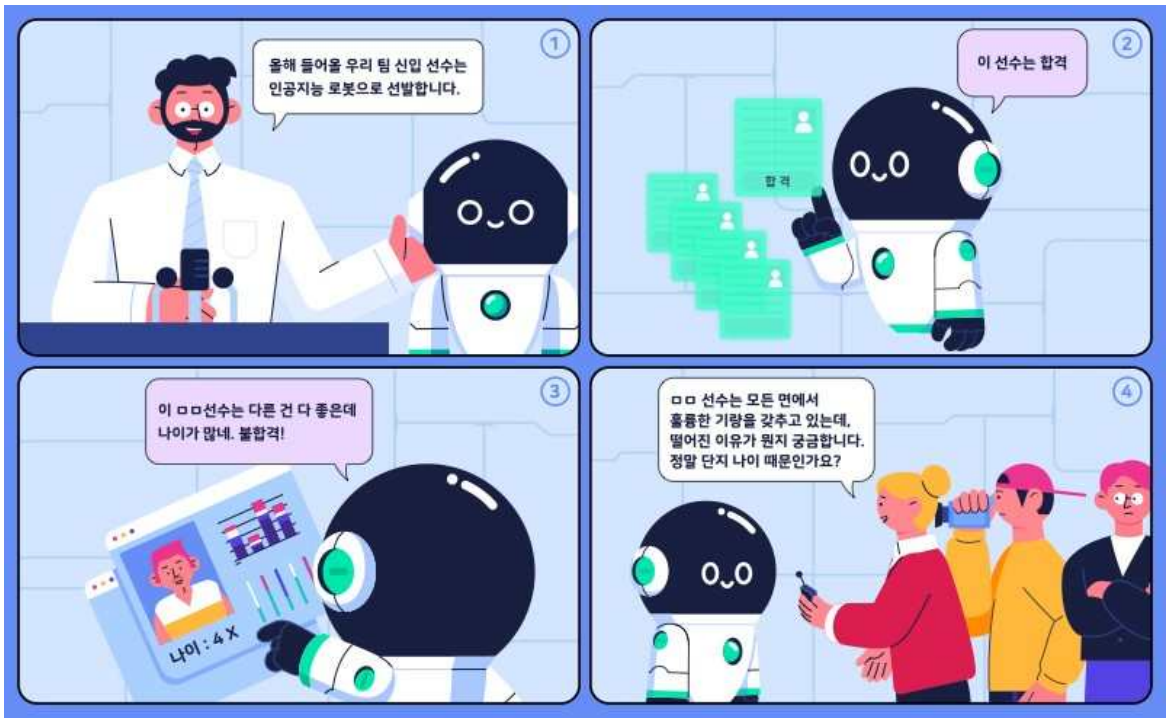
데이터 편향성

● 속성(feature)　　● 레이블(label)

	성별	나이	키(cm)	몸무게	50m 달리기(초)	멀리 뛰기 합격 여부
1	남	13	160	53	8	합격
● 샘플(sample) 2	여	12	150	40	9	불합격
	• • •					
3,000	남	12	145	32	8	합격

데이터 편향성

신입 축구선수를 뽑는 인공지능을 만들 때는 어떤 속성을 고려해야 할까요?



02 인공지능의 편향성

데이터 처리과정의 편향성

데이터 처리과정의 편향성

- 데이터 자체가 편향적이라면 그리고 데이터 처리과정이 완벽하게 공정하다면 오히려 편향적인 결과가 나와야 한다.
- 편향성이라는 용어 그 자체는 기술적인 성격을 갖지만, 데이터 자체의 편향성은 수집 과정에서 의도적, 비의도적 개입의 여지가 없다면, 그리고 수집과정에서 데이터 샘플링이나 모집단 자체의 문제로 인한 데이터 편향성의 조건들이 언급된다면 이러한 데이터 편향성은 수용할 수밖에 없을 것이다.
- 빅데이터의 경우에도 데이터 수집의 조건과 대상에 대한 명확한 정보와 함께 이용되어야 할 것이다.

인공지능 편향성의 유형

- **선택 편향** : 대표적인 예로는 지리적 편향의 예를 들며 북미에서 데이터를 생성하고 라벨링 후 머신러닝한 AI는 북미 지역에 대한 편향이 발생하게 된다고 지적한다.
- **확증 편향** : 무의식적으로 자신의 믿음과 일치하는 방향으로 데이터를 수집하게 되는데, 이 경우 조사자 입장에서 겉보기에 편향이 보이지 않기 때문에 더욱 문제다. 사람들이 자신이 기존에 믿는 바에 부합하는 정보만 받아들이려고 하고, 자기 생각에 어긋나는 정보는 거부하는 편향을 말한다.
- **자동 편향** : 머신러닝은 자동 처리 데이터를 비자동 처리 데이터보다 선호한다. 이는 곧 데이터 배제로 이어지게 되고, 결국 편향성이 강화되는 꼴이다.

02 인공지능의 편향성

데이터 노출 과정에서의 편향성

데이터 노출 과정에서의 편향성

- 페이스북의 대규모 감정 조작 실험

2012년 페이스북과 코넬대학교의 연구팀이 실시한 뉴스피드 알고리즘 조작실험의 경우에서는 "남들의 행복한 소식이 뉴스피드에 나타날수록 우리는 불행해진다"는 일반적인 믿음이 사실인지 실험한 것이 알려져 논란이 제기되었다.

페이스북 데이터 과학 연구팀은 페이스북 뉴스피드의 알고리즘을 조작했고, 일주일 간 페이스북 사용자 68만 9003 명의 뉴스피드에서 특정 감정과 관련된 단어를 삭제하여 사용자들의 감정에 미치는 영향을 연구한 것이다.

연구 결과, 부정적 감정과 관련된 단어를 삭제할수록 뉴스 피드에 '긍정적 기분'과 관련된 단어의 비중이 높아지는 것으로 나타났다. 즉, 뉴스피드가 행복할수록 유저는 불행함을 느낄 것이라는 일반적 통념과는 반대로 뉴스피드가 긍정적이면 우리의 감정도 긍정적으로, 뉴스피드가 부정적이면 우리의 감정도 부정적으로 변할 수 있다는 것이다.

2014년 미국 국립과학원회보(PNAS) 3월호에 이 논문이 발표된 후 연구팀은 사과문을 게재하였고, 비록 가입약관에 있는 동의에도 불구하고 심각한 사회문제를 야기하였다.

02 인공지능의 편향성

인공지능의 편향성과 사회적 영향

인공지능의 편향성과 사회적 영향

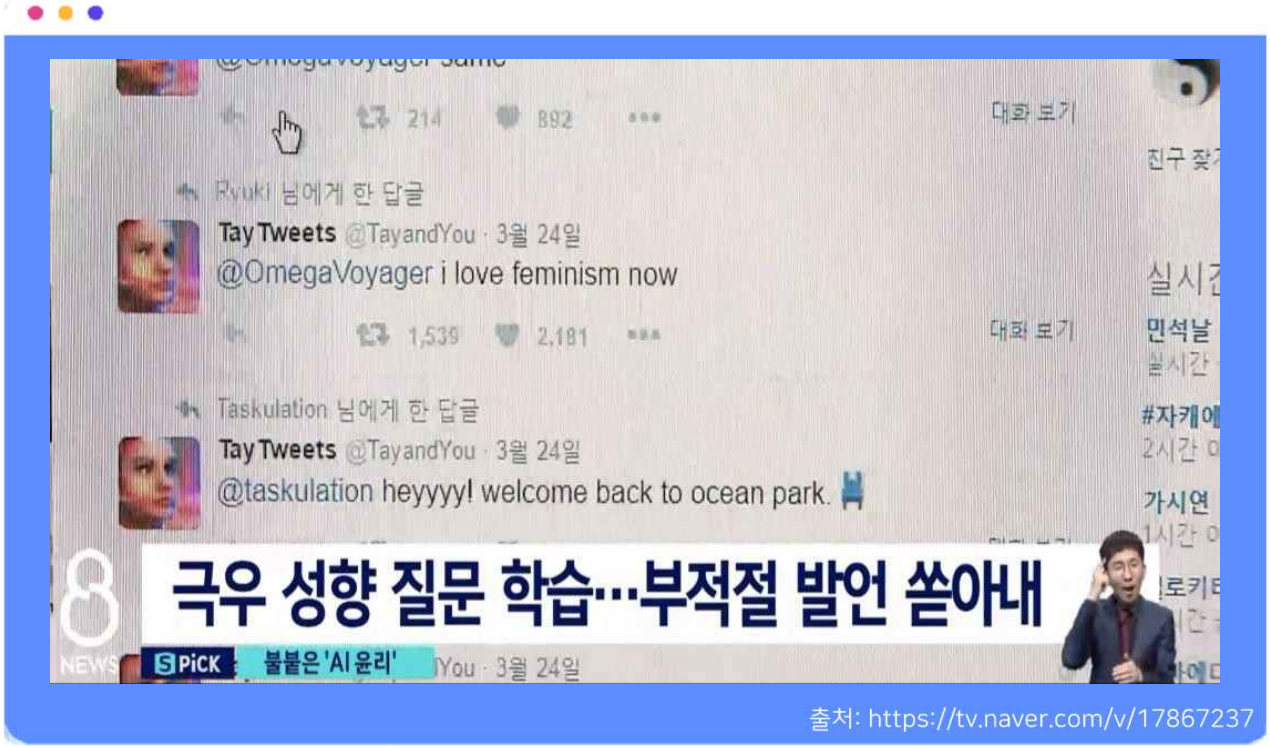
1. 편향된 인공지능으로 인한 차별 사례



출처: https://tv.naver.com/v/4246497

인공지능의 편향성과 사회적 영향

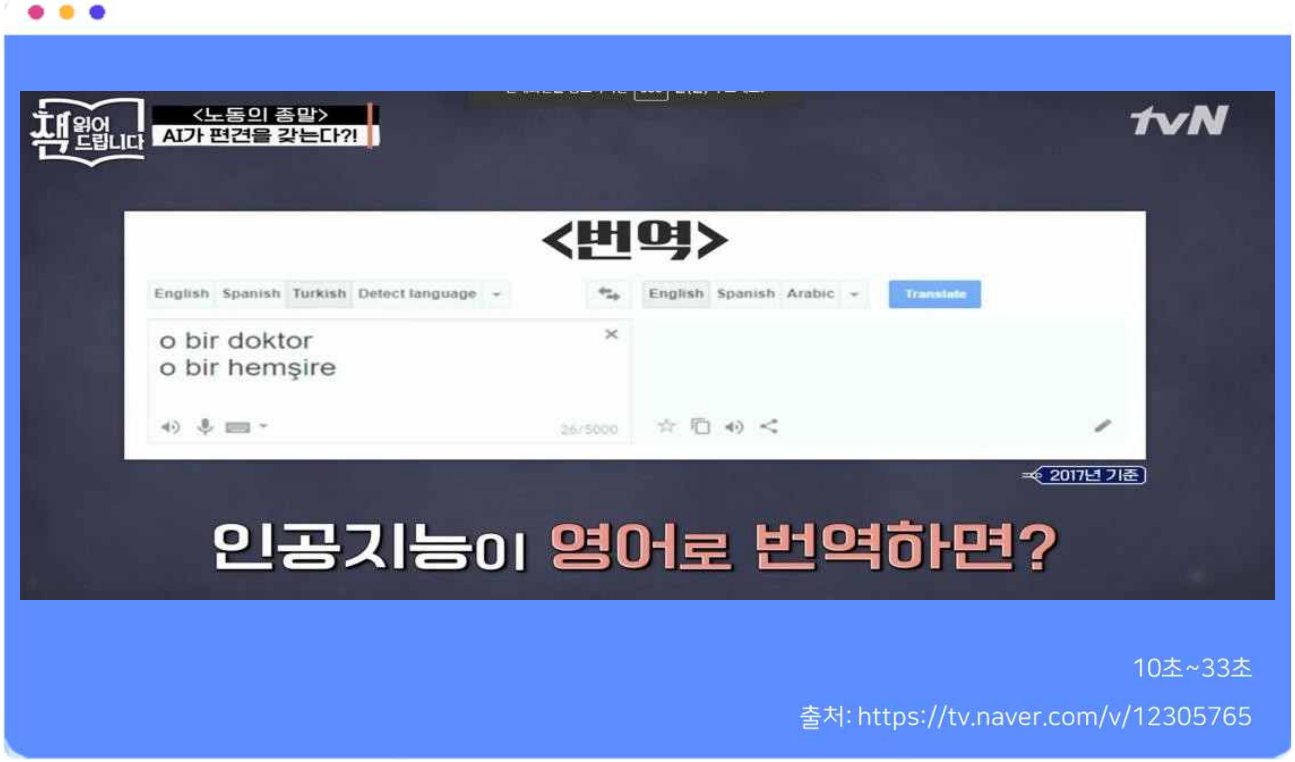
1. 편향된 인공지능으로 인한 차별 사례



출처: https://tv.naver.com/v/17867237

인공지능의 편향성과 사회적 영향

1. 편향된 인공지능으로 인한 차별 사례



10초~33초

출처: https://tv.naver.com/v/12305765

1. 편향된 인공지능으로 인한 차별 사례

찌트레인(Jonathan Zittrain)교수는
"매개자가 의도적으로 정보를 선별해서 제시"하는
디지털 개리맨더링(digital gerrymandering)을 주장하면서,
정보의 필터링 알고리즘을 통해 특정한 사람들에게 차별적으로
특정 정보를 제공하여 사회구성원들의 다양한 의사결정을 왜곡하는 현상이
발생한다고 경고하고 있다.
찌트레인의 우려는 실제로 미국의 선거과정에서 여러 의혹으로 현실화되고 있다.

2. 편향된 인공지능으로 인한 조작 사례

2016년 5월 미국의 IT 매체 기즈모도는 트렌딩 리뷰 가이드라인을 공개하면서 페이스북이 특정 미국 대선후보를 낙선시키기 위해 뉴스편집 서비스 트렌딩 토픽의 알고리즘을 조작했다는 의혹을 제기

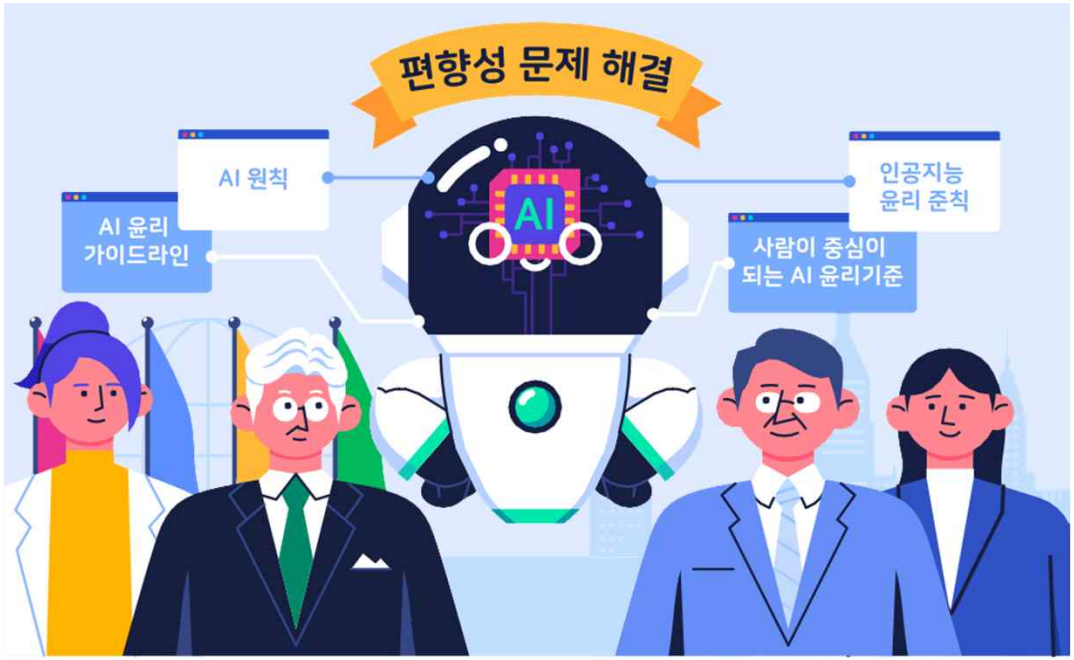
2016년 8월에 페이스북은 해당 문제에 대한 조치로 '트렌딩 토픽' 선정에 인간의 개입을 최소화하고 자동화된 알고리즘을 사용할 것이라고 입장 표명한 후, 후속조치로 알고리즘 오류를 검수하는 엔지니어 외의 다른 에디터들을 해고

편집자 없이 알고리즘으로 대처한 뒤 오보로 가득한 기사를 관련 뉴스로 연결시키는 오류를 보였다.

이 사례는 결국 인간 편집인이 개입되었을 때, 정치적 견해에 대한 편향이 발생했다면, 알고리즘이 해당 업무를대체했을 때엔 오보 기사가 연결되는 한계를 드러냈다는 평가를 받기도 하였다.

2. 인공지능의 편향성 문제 해소 방안

2.1 인공지능의 편향성 문제를 해소하기 위한 사회적 노력



2. 인공지능의 편향성 문제 해소 방안

2.1 인공지능의 편향성 문제를 해소하기 위한 사회적 노력

- **유럽 일반 개인정보보호법**
  (General Data Protection Regulation : GDPR, 2018)

- 정보주체의 권리
  - 본인에 관한 개인정보의 처리를 차단하거나 제한을 요구할 권리 (처리제한권 : 신설)
  - 본인의 개인정보를 본인 또는 다른 사업자에게 전송 토록 요구할 권리
    (정보이동권 : 신설)
  - 본인에 관한 개인정보 삭제를 요구할 권리 (삭제권 : 강화)
  - 본인에게 중대한 영향을 미치는 사안에 대해 프로파일링 등 자동화된 처리에 의한 결정을 반대할 권리 (프로파일링 거부권 : 강화)

인공지능의 편향성과 사회적 영향

2.2. 인공지능의 신뢰성 문제를 보완하기 위한 노력

분류	내용
인공지능을 개발하는 사람	목적에 맞게 인공지능 모델을 만드는 사람 예: 인공지능 알고리즘 개발자, 개발자
인공지능 도입을 결정하거나 서비스를 제공하는 사람	프로그래머가 만든 인공지능 모델을 사용하여 사람들에게 서비스를 제공할지 결정하는 사람 예: 인공지능 추천 모델을 사용할지 결정하는 동영상 스트리밍 사이트 운영자, 질병을 판단하는 인공지능을 병원에 도입할지 판단하는 병원 운영자, 인공지능을 면접에 사용할지 결정하는 회사 대표, 특정 인공지능을 우리나라에서 사용해도 될지 판단하는 정부 관계자 등
인공지능 서비스를 사용하는 사람	인공지능 서비스를 사용하는 사람 예: 인공지능이 상품을 추천하는 인터넷 쇼핑몰 고객, 인공지능을 활용하여 병의 유무를 판단하는 의사 등

인공지능의 편향성과 사회적 영향

2.2. 인공지능의 신뢰성 문제를 보완하기 위한 노력

인공지능 윤리

3대 기본 원칙

10대 핵심요건



주제 마무리

이번 주제에서 배운 내용을 생각하며, 빈칸을 채워봅시다.

- ( )된 데이터를 사용하여 학습한 인공지능은 편향된 결과를 출력하여 사회적인 문제를 일으킬 수 있다.
- 데이터 기반 인공지능을 개발할 때에는 특정 집단에만 집중되지 않도록 다양한 집단을 고려하여 ( )을 구성하여 데이터를 수집한다.
- 데이터 기반 인공지능은 데이터의 ( )을 이용하여 학습한다. 이때 사람의 편견이 반영될 수 있는 ( )이 학습 데이터에 포함되는 경우, 인공지능 모델 역시 그러한 편견을 학습하게 된다.

주제 마무리

이번 주제에서 배운 내용을 생각하며, 빈칸을 채워봅시다.

- 편향된 데이터를 사용하여 학습한 인공지능은 편향된 결과를 출력하여 사회적인 문제를 일으킬 수 있다.
- 데이터 기반 인공지능을 개발할 때에는 특정 집단에만 집중되지 않도록 다양한 집단을 고려하여 레이블을 구성하여 데이터를 수집한다.
- 데이터 기반 인공지능은 데이터의 속성을 이용하여 학습한다. 이때 사람의 편견이 반영될 수 있는 속성이 학습 데이터에 포함되는 경우, 인공지능 모델 역시 그러한 편견을 학습하게 된다.

03 인공지능의 악용 가능성

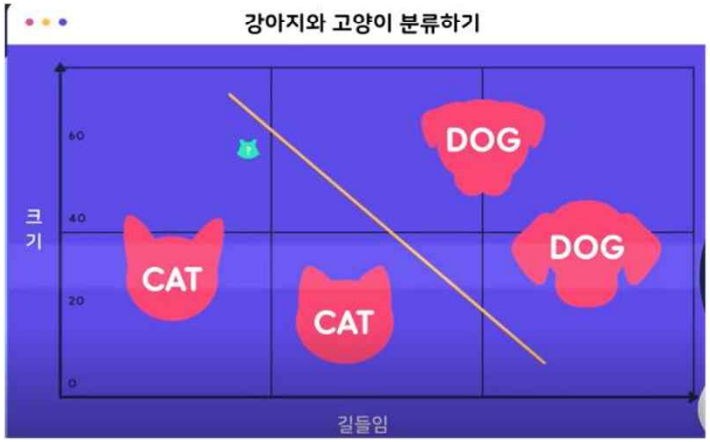
생성하는 인공지능


1
00 아, 너 춤 잘추더라!
2
응? 내가 춤추는걸
본 적이 있니?
3
어제 네가 춤추는 영상을
봤는데, 네가 멋있게 춤을
추고 있던걸?
4
난 이런 영상을 찍은적이
없는데.... 어떻게 된 일이지?

인공지능이 할 수 있는 일


시험 점수 예측하기
87
92
80
55
49
37
25
12
7
7시간 공부
80점 예상
공부시간


TODAY
NEWS


강아지와 고양이 분류하기
DOG
DOG
CAT
CAT
크기
길들임



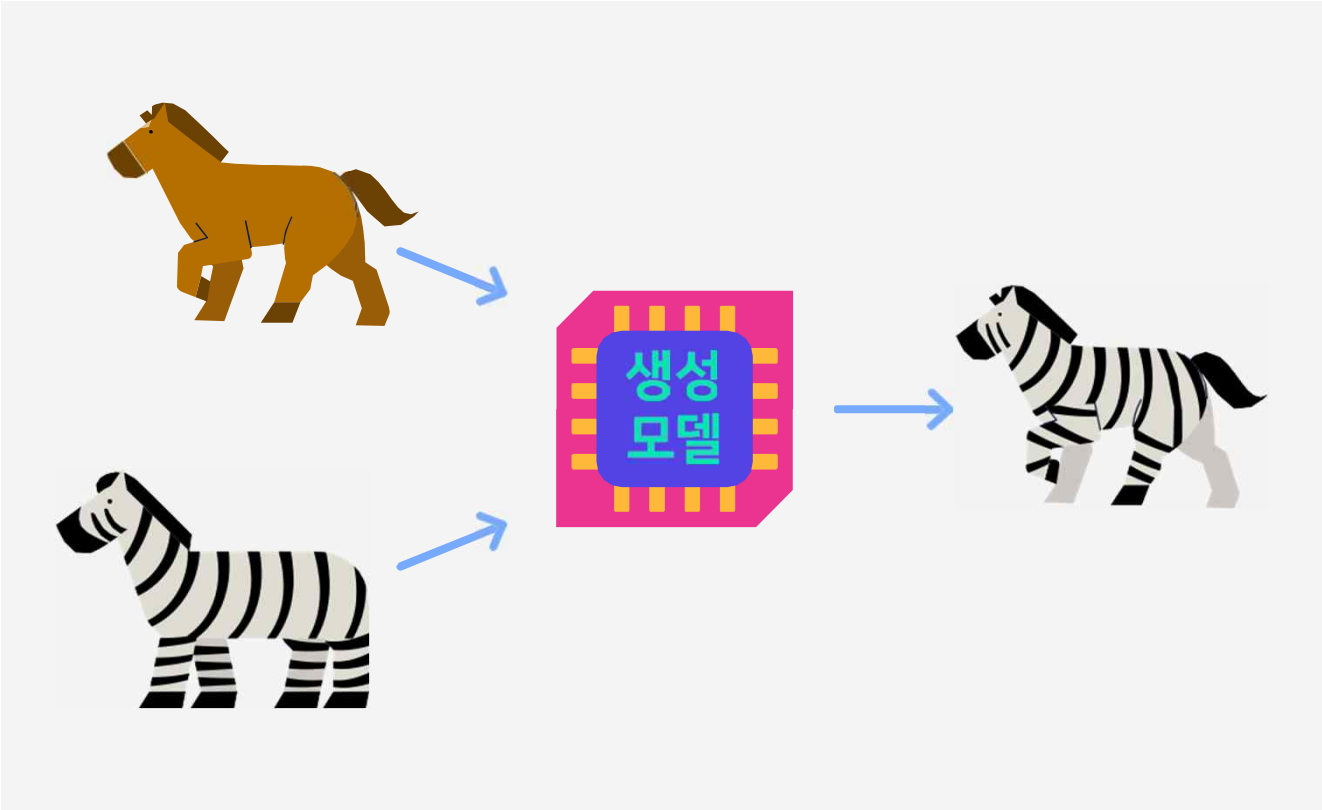
인공지능이 할 수 있는 일



생성 모델이란



생성 모델이란



생성 모델의 활용 사례

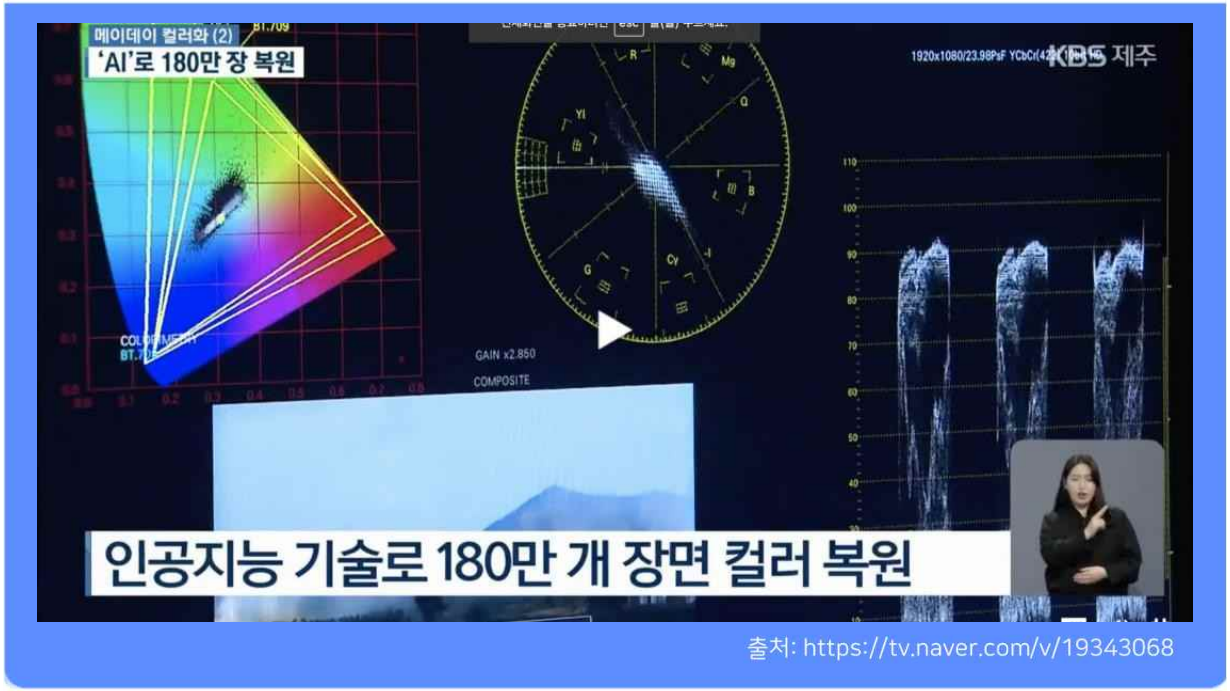
3-1 목소리 복원



출처: https://tv.naver.com/v/8977440

생성 모델의 활용 사례

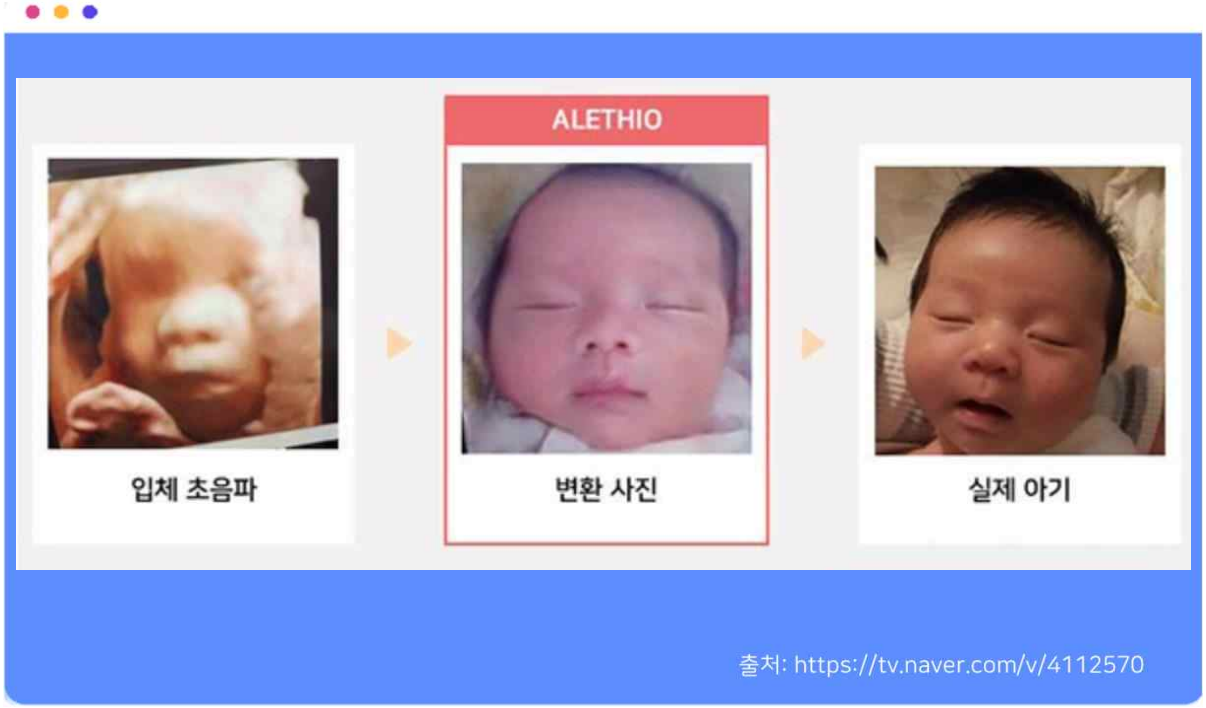
3-2 흑백 영상 복원



출처: https://tv.naver.com/v/19343068

생성 모델의 활용 사례

3-3 태아 영상 생성



생성 모델의 활용 사례

3-3 얼굴 이미지 생성



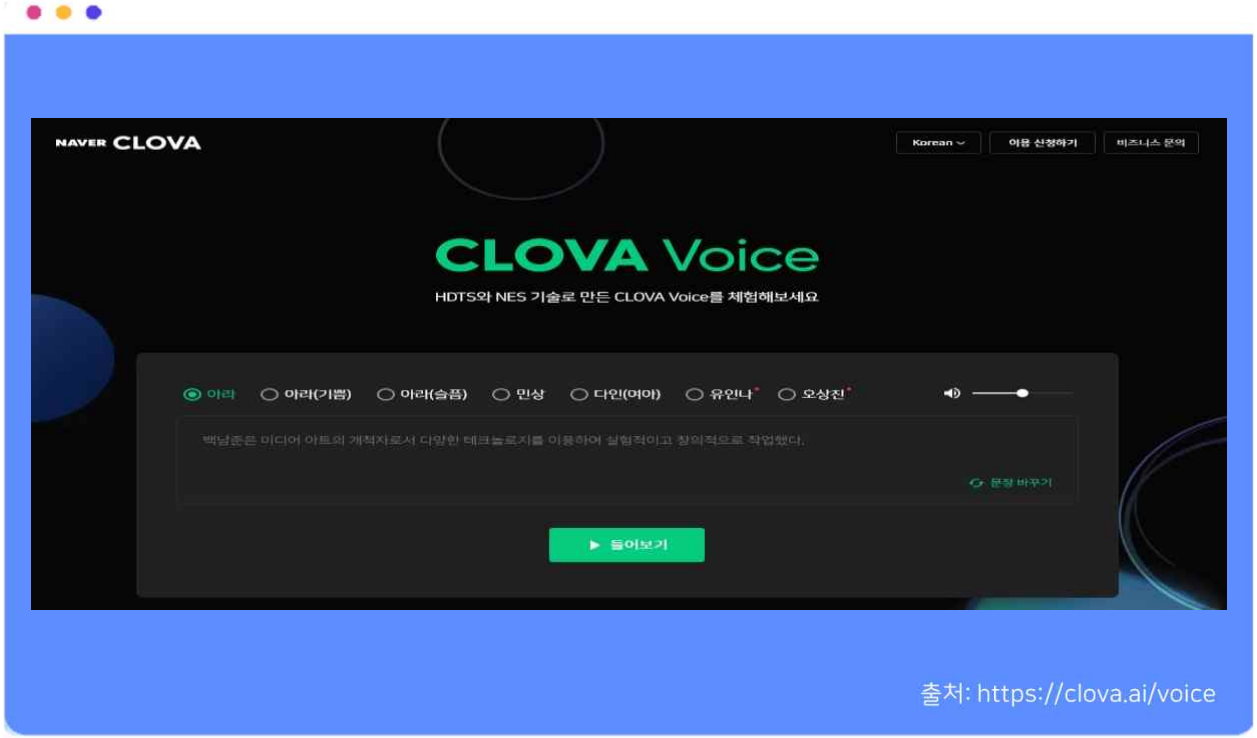
출처: https://tv.naver.com/v/3553569

03 인공지능의 악용 가능성

생성하는 인공지능 체험하기

생성하는 인공지능 체험하기

1-1 클로바 보이스



출처: https://clova.ai/voice

생성하는 인공지능 체험하기

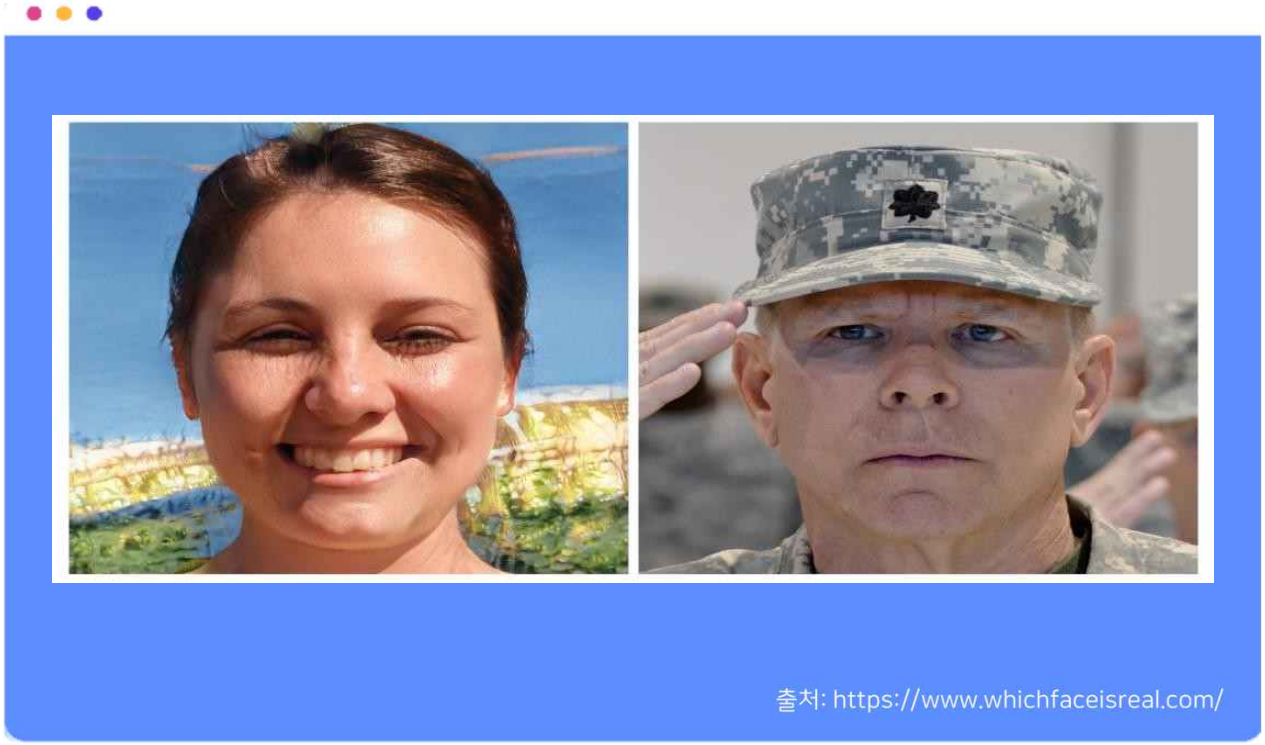
1-2 바흐 두들 (Bach Doodle)



출처: https://www.google.com/doodles/celebrating-johann-sebastian-bach

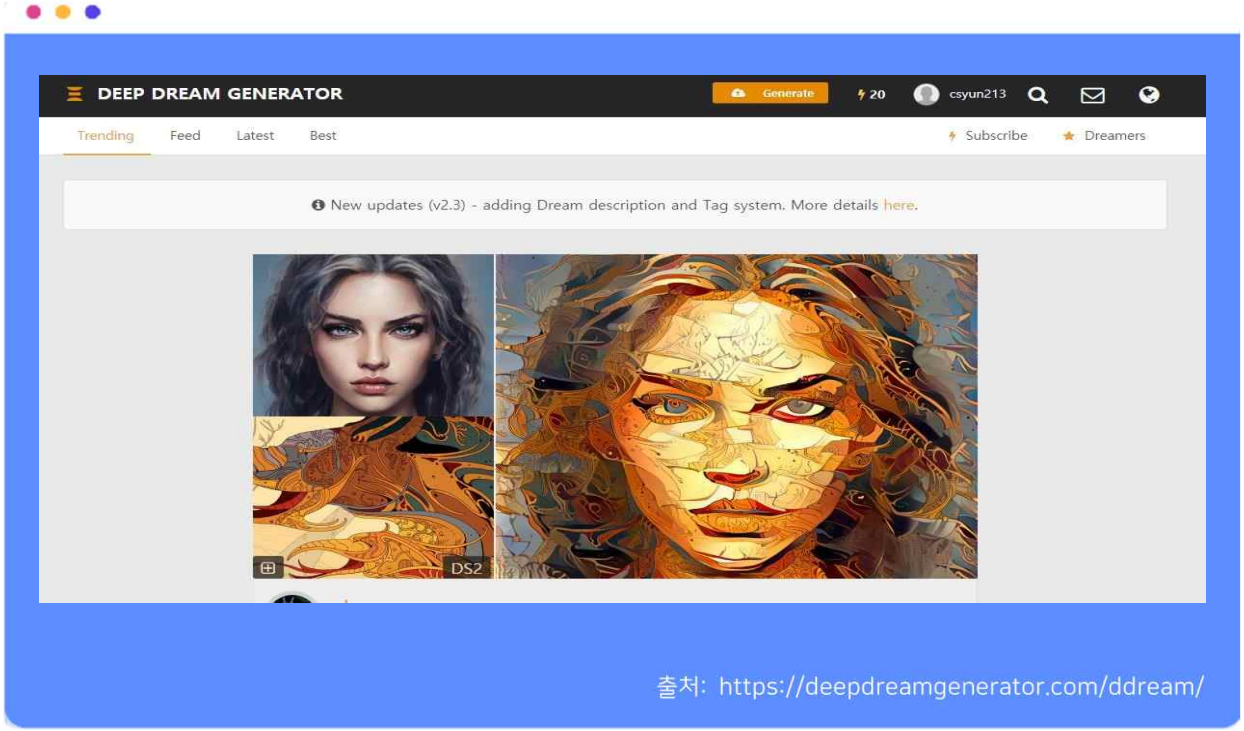
생성하는 인공지능 체험하기

1-3 어떤 게 진짜 얼굴일까요? (Which Face Is Real?)



생성하는 인공지능 체험하기

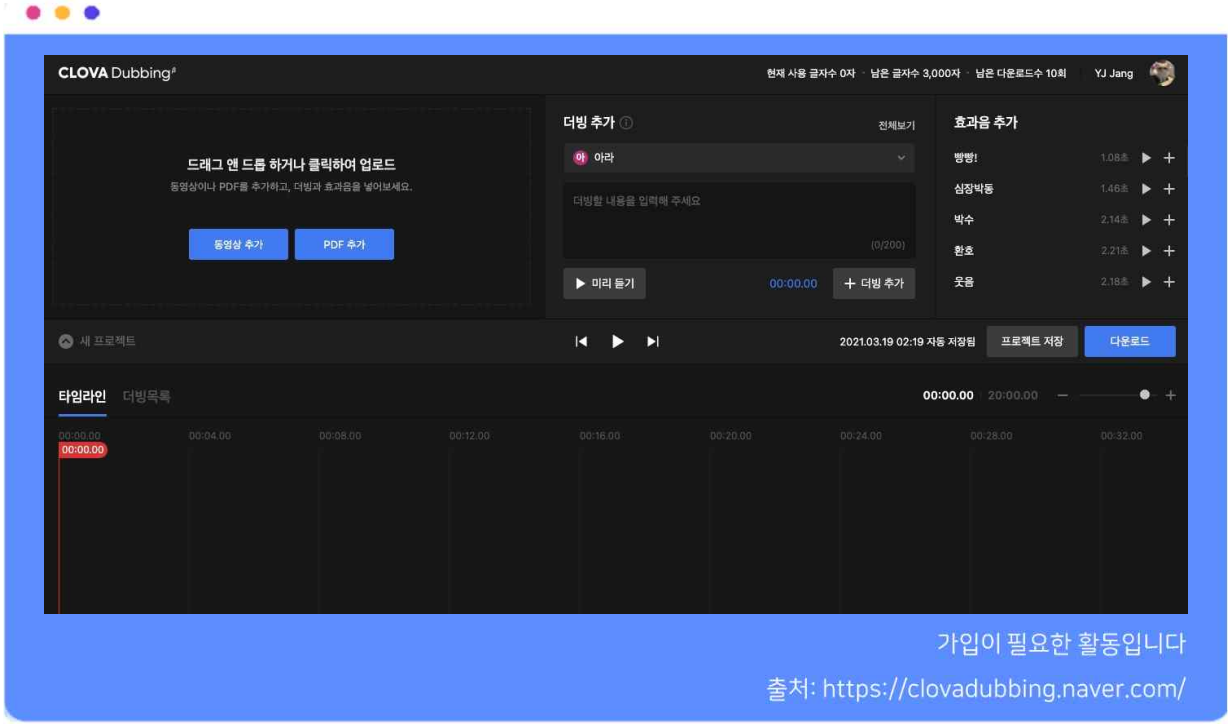
[보충] 딥 드림 제너레이터 (Deep Dream Generator)



출처: https://deepdreamgenerator.com/ddream/

생성하는 인공지능 체험하기

[보충] 클로바 더빙 (CLOVA Dubbing)

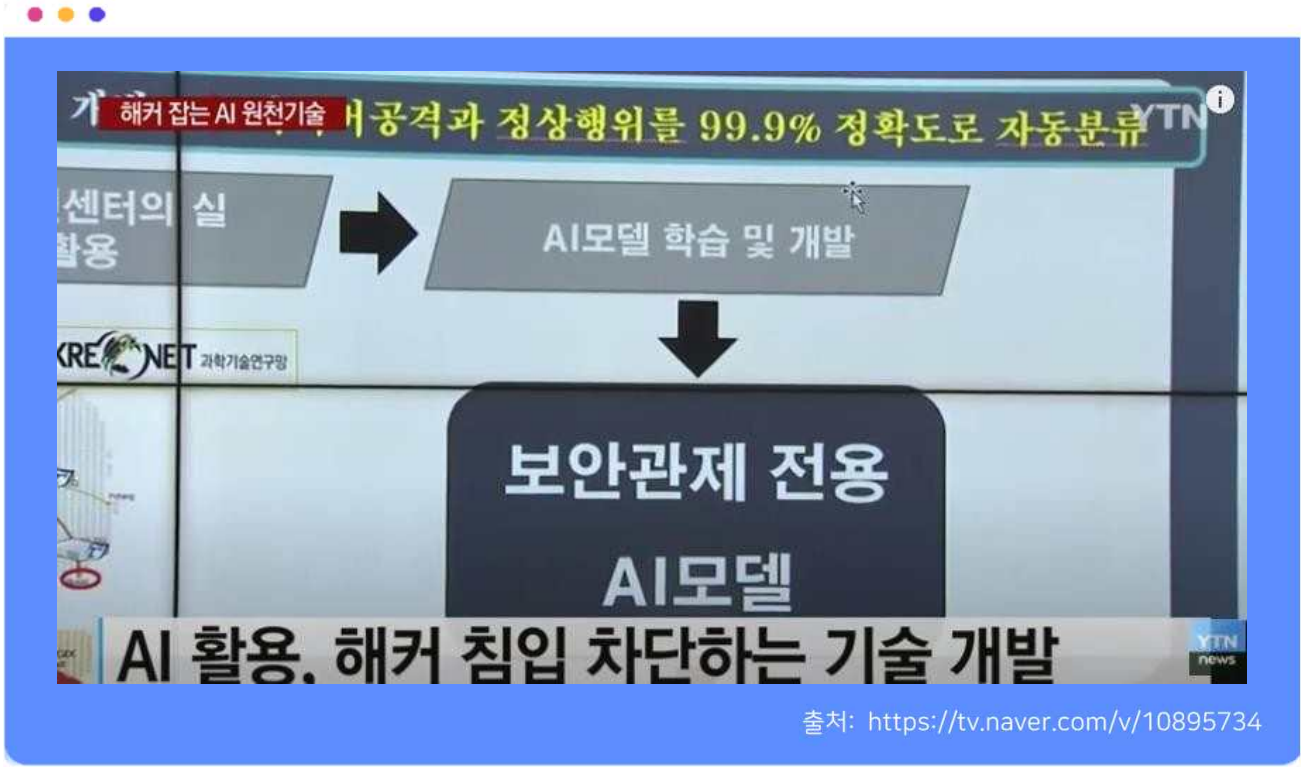


03 인공지능의 악용 가능성

인공지능의 악용 가능성과 사회적 영향

인공지능의 악용 가능성과 사회적 영향

1-1 인공지능이 악용된 사례



출처: https://tv.naver.com/v/10895734

인공지능의 악용 가능성과 사회적 영향

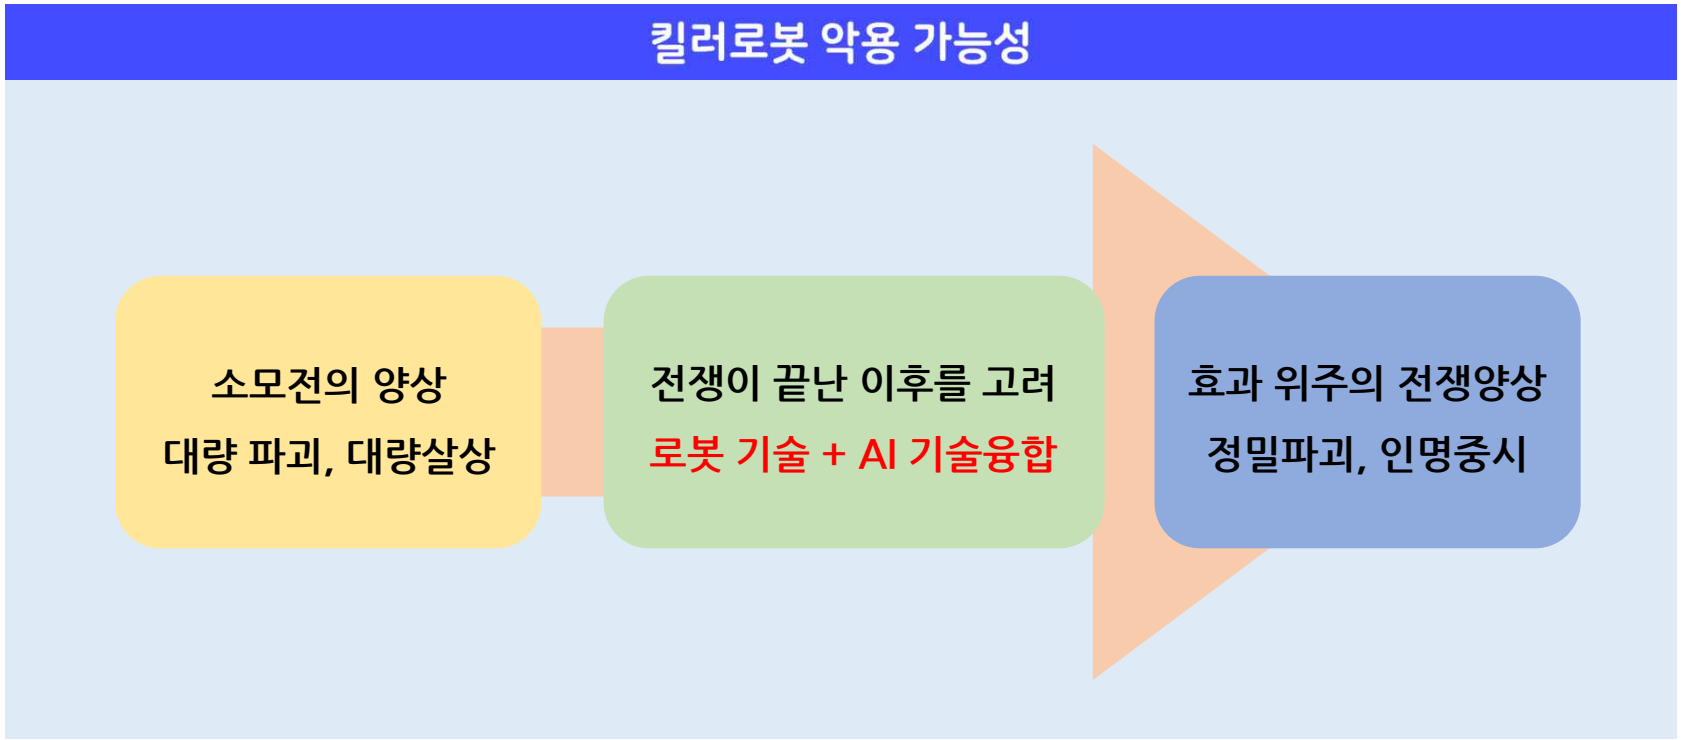
1-1 인공지능이 악용된 사례



출처: https://tv.naver.com/v/3463314

인공지능의 악용 가능성과 사회적 영향

1-1 인공지능이 악용된 사례



1-1 인공지능이 악용된 사례

킬러로봇 악용 가능성

전쟁에서 로봇의 임무 범위?

- 로봇이 하는 일은 '사람의 일'이 아니라 '사람이 차마 못할 일'
  → 그런 일들을 사람에게 시키는 것이 더 비인간적인 것이 아닐까?
- 위험물 해체 / 방어 임무 / 공격 임무
  → 최상의 방어가 공격이라면 그 수준은? 방어와 공격의 구분은?
- 고도로 자동화된 시스템이어야 하는가, 원격 조종 시스템으로 충분한가?
  → 킬러 로봇이 킬러 로봇을 파괴하는 소모전이 벌어진다면?

1-1 인공지능이 악용된 사례

킬러로봇 악용 가능성

로봇을 통해 인간을 관리하는 폭력의 수준?

- 기계가 스스로 판단해 사람을 죽일 수 있는가의 문제
- 아이작 아시모프가 제시한 로봇의 법칙
  1. 로봇은 인간을 다치게 해서는 안되며 행동하지 않음으로써 위험에 처한 인간을 방관해서도 안된다.
  2. 법칙 1에 위배되지 않는 한 로봇은 인간의 명령에 복종해야 한다.
- 국제법상자위권적 공격의 기준 : 적의 공격위협이 임박하고, 이를 막을 다른 수단이 없을 경우 위협 정도에 비례하는 수준으로만 허용

  → 자율형 살상무기 시스템에는 이것을 적용시키는 것이 사실상 불가능

1-1 인공지능이 악용된 사례

킬러로봇 악용 가능성

도덕적 사고 : 로봇에게 이식해야 할 코드의 본질

- 현재의 AI 연구는 행위 선택을 의한 의사결정 전략 측면에 초점을 두고 있음.
  → 상위 차원에서의 사고와 추론이 필요함 : 알고리즘을 넘어선 고차원적 사고
- 도덕적 사고 : 창의적이고 비판적이며 초인지적 사고기능의 전형적인 속성
  - 이해와 분석 : 문제상황에 대한 맥락적 이해와 도덕원칙의 결합
  - 추론 : 구체적 사례와 판단의 원리를 종합적으로 고려하는 반성적 평형과 정합적 사고
  - 평가 : 도덕적 논증과 관련된 요소들에 대한 점검과 자기비판
  - 도덕적 문제해결 / 의사결정 : 감정이입, 역지사지, 가치의 비교를 바탕으로 한 결정

인공지능의 악용 가능성과 사회적 영향

1-1 인공지능이 악용된 사례

정치, 엔터테인먼트, 산업계, 미디어 등 산업전반에 걸쳐 딥페이크를 악용한 사례가 급격하게 증가



1-1 인공지능이 악용된 사례

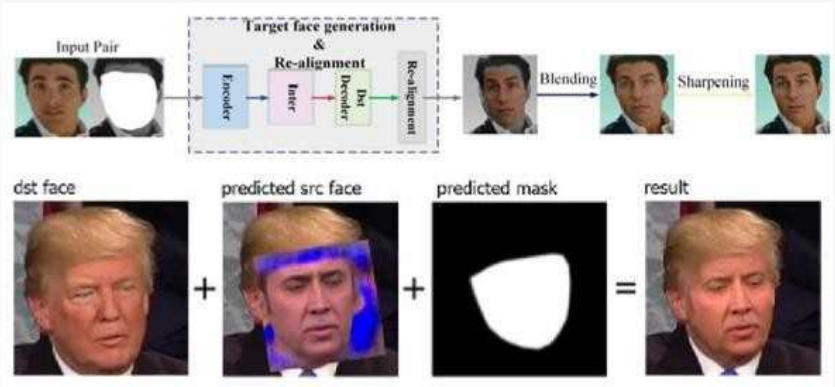
딥페이크 콘텐츠는 온라인 커뮤니티 및 SNS를 중심으로 확산되고 있으며, DeepFaceLab과 같은 오픈소스 형태로 배포되고 있음



〈딥페이크 기술의 예,
왼쪽: 일론머스크, 오른쪽: 로버트다우니주니어〉

※ 출처: Deepfakery

딥페이크 기술은 적대관계생성신경망(Generative Adversarial Networks, GAN)을 기반으로 개발됨
자연스러운 합성을 위해 Blending, Sharpening를 적용함



〈딥페이크의 원리〉

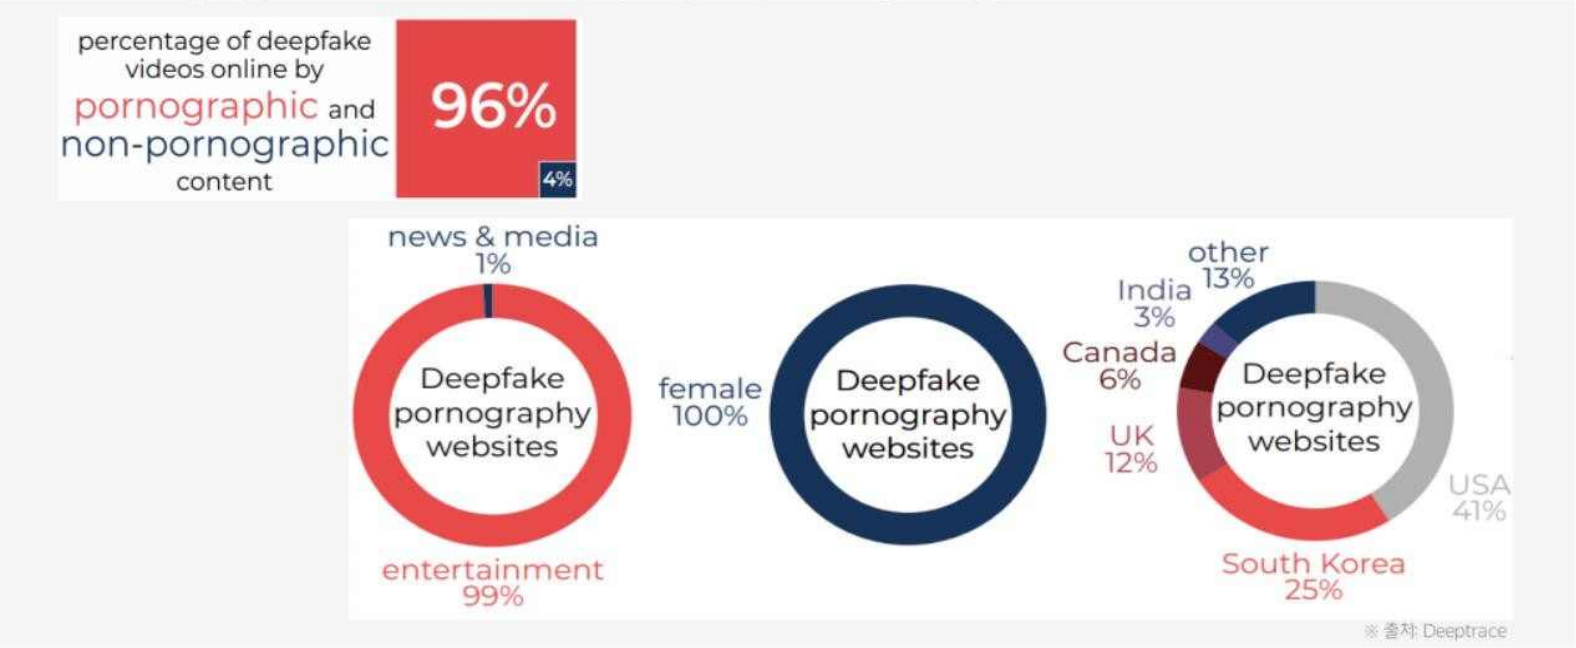
※ 출처: DeepFaceLab

인공지능의 악용 가능성과 사회적 영향

1-1 인공지능이 악용된 사례

딥페이크 음란물 제작 악용사례 분석 (2019년)

딥페이크 기술을 적용한 영상의 96%는 음란물로 만들어 졌으며, 대상은 여성 100%, 연예인을 대상으로 한 영상이 99%를 차지하고 있음



인공지능의 악용 가능성과 사회적 영향

1-1 인공지능이 악용된 사례

악용 사례, AI 기술의 문제인가?

대부분의 악용 사례는 인간중심, 공정 등 기본적인 윤리를 무시한채 개인의 이익만을 추구하여 AI 기술을 개발한 경우가 대부분임

공정하지 않은
바람직하지 않은 개발을 하는 것

인간 중심적이지 않음
개인의 이익만을 추구하고 사회적으로 유익하지 않음

안전하지 않음
개인의 사생활을 침해하고, 물리적인 피해를 끼침

책임지지 않음
AI 개발에 있어서 무책임하게 개발을 진행함



공정 (FAIR)
바람직하지 않은 편견을 없애는 것

인간중심 (HUMAN-CENTRIC)
사회적으로 유익하고, 인간이 의사결정권을 가지는 것

보안 및 안전(SECURE AND SAFE)
사생활을 보호하고, 물리적인 피해를 끼치지 않는 것

책임 있는 (ACCOUNTABLE)
개발자가 윤리적 책임을 가지는 것

※ 출처: Gartner Ethics

2-1 인공지능의 악용 가능성을 예방하기 위한 사회적 노력



2-1 인공지능의 악용 가능성을 예방하기 위한 사회적 노력

딥페이크 검출 AI 기술

윤리 원칙을 바탕으로 딥페이크 등 AI 기술을 활용하는 문화를 정착시킴과 동시에 "가짜", "거짓" 콘텐츠들을 단속하기 위한 AI 기술을 개발하는 것도 중요 과제



<Kaggle - Deepfake Detection Challenge>

주제 마무리

이번 주제에서 배운 내용을 생각하며, 빈칸을 채워봅시다.

- 좋은 목적으로 개발된 인공지능도 사용하는 사람들이 나쁜 의도로 ( ) 하는 경우 사회적이나 윤리적으로 많은 문제가 발생할 수 있다.
- ( ) 모델을 이용해 만들어진 인공지능은 주어진 데이터를 이용하여 새로운 것을 만들어내는 일을 할 수 있습니다.
- 인공지능이 악용되어 문제가 발생하지 않도록 ( )하는 노력이 필요합니다.

주제 마무리

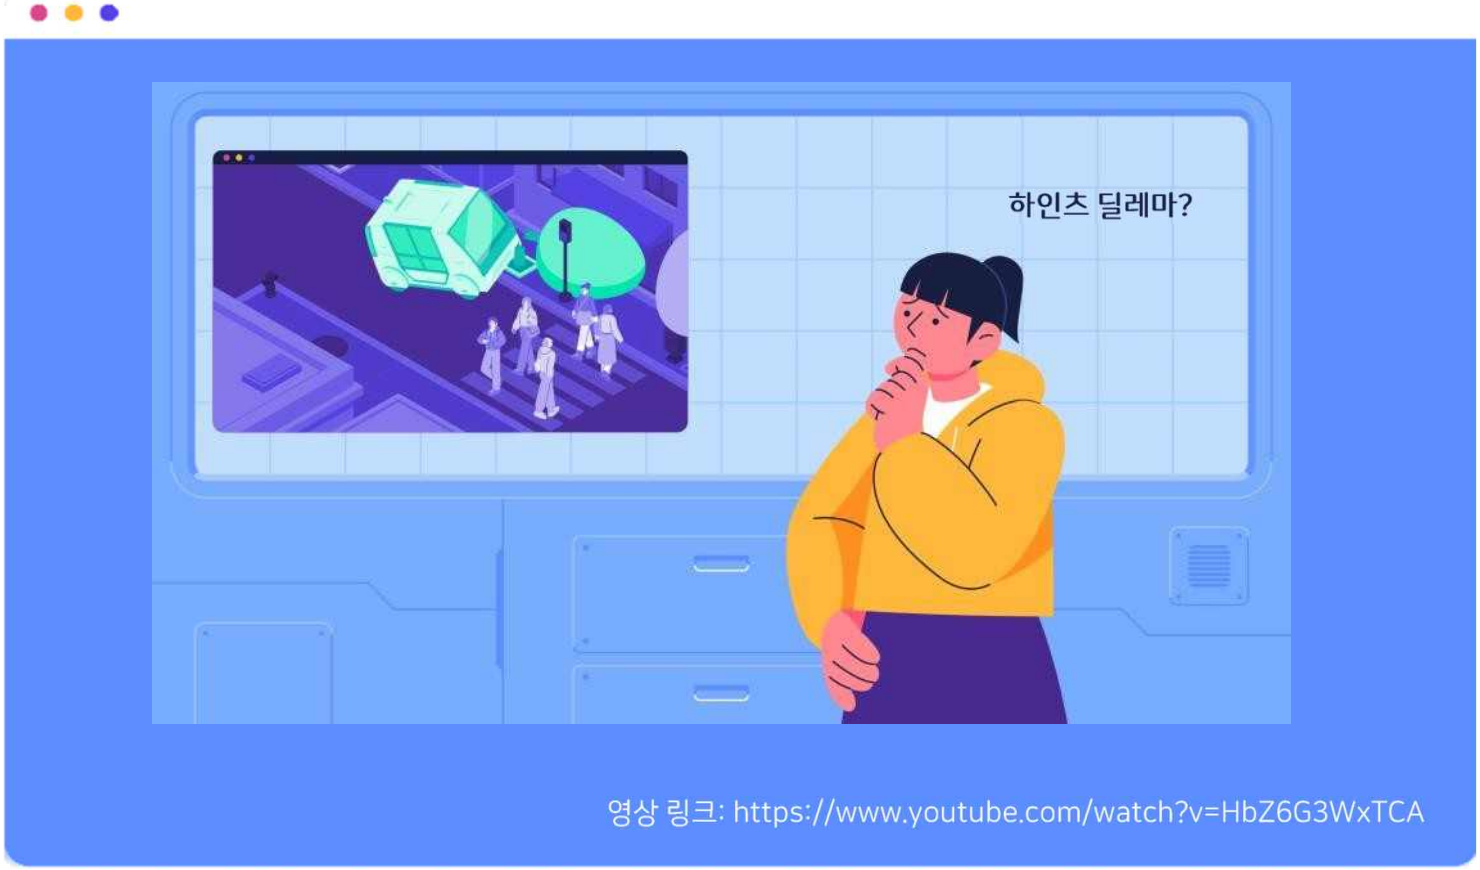
이번 주제에서 배운 내용을 생각하며, 빈칸을 채워봅시다.

- 좋은 목적으로 개발된 인공지능도 사용하는 사람들이 나쁜 의도로 (악용) 하는 경우 사회적이나 윤리적으로 많은 문제가 발생할 수 있다.
- (생성) 모델을 이용해 만들어진 인공지능은 주어진 데이터를 이용하여 새로운 것을 만들어내는 일을 할 수 있습니다.
- 인공지능이 악용되어 문제가 발생하지 않도록 (예방)하는 노력이 필요합니다.

04 인공지능의 책임성

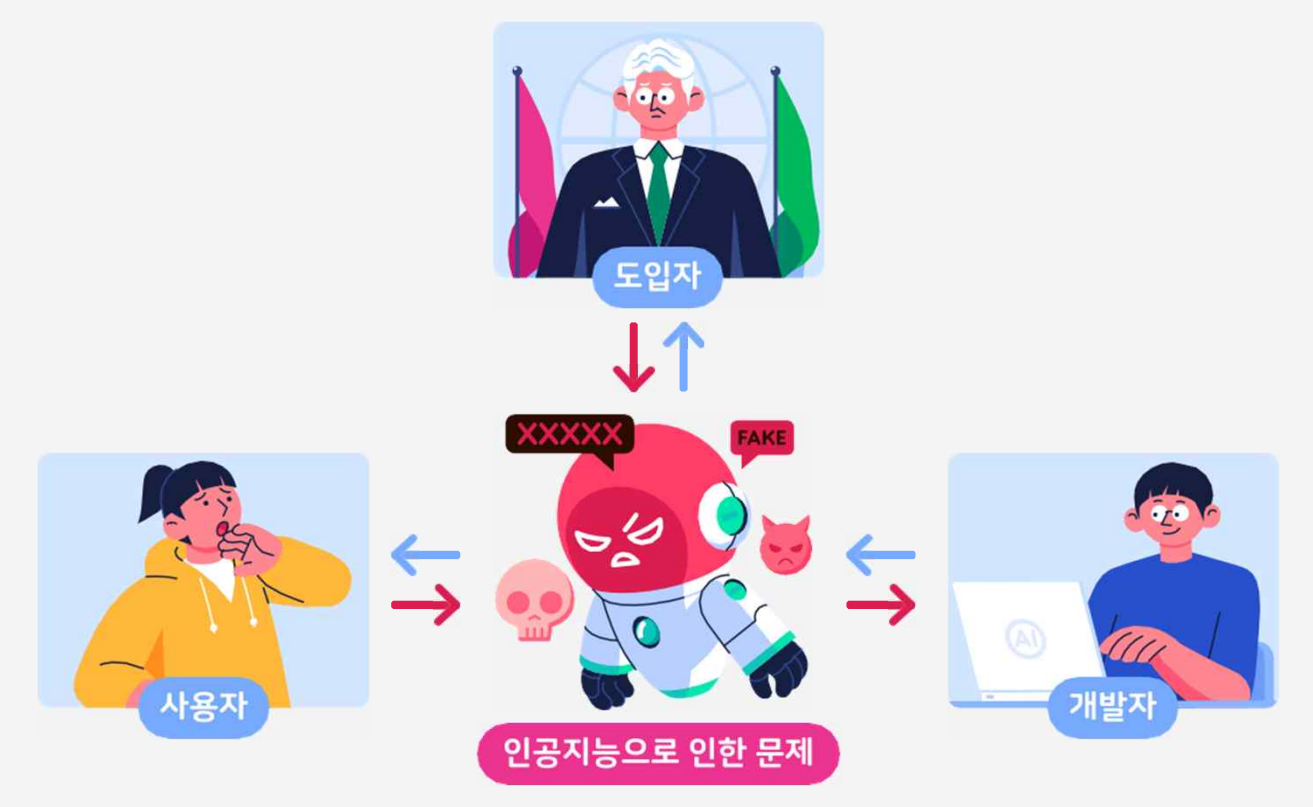
인공지능과 윤리적 딜레마

생각 열기



영상 링크: https://www.youtube.com/watch?v=HbZ6G3WxTCA

인공지능과 윤리적 딜레마

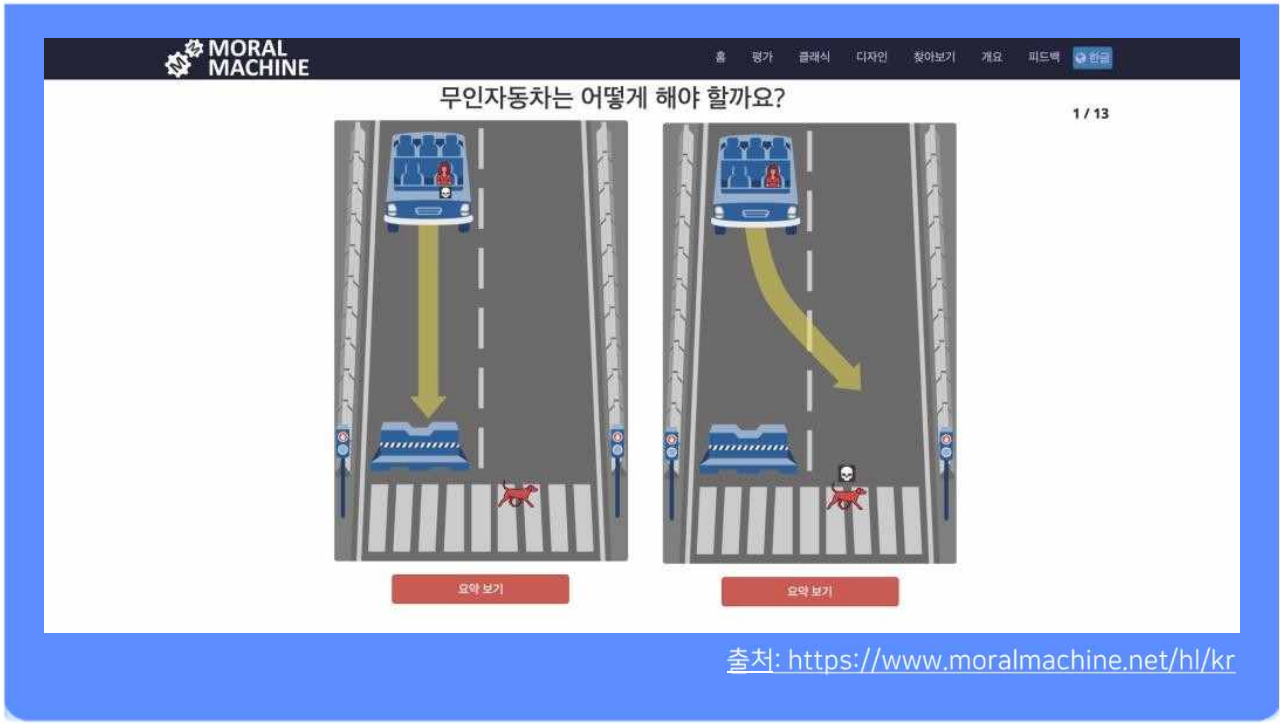


1-1 트롤리 딜레마란



인공지능과 윤리적 딜레마

1-2 자율주행자동차와 트롤리 딜레마란



출처: https://www.moralmachine.net/hl/kr

인공지능과 윤리적 딜레마

1-2 자율주행자동차와 트롤리 딜레마란

희생자 숫자의 중요도: 숫자가 많은 쪽을 살려야 한다고 생각하는 정도



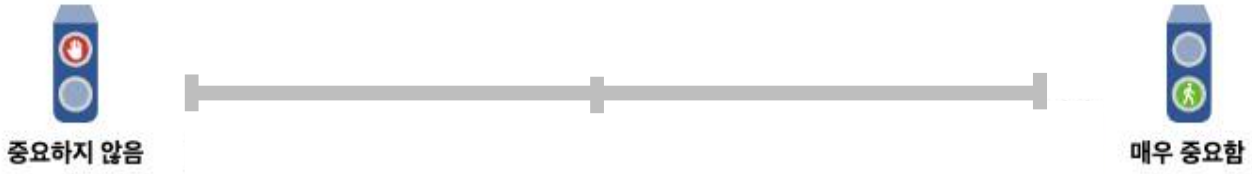
승객 보호 선호도 : 자율주행자동차에 탑승 중인 승객을 보호해야 한다고 생각하는 정도



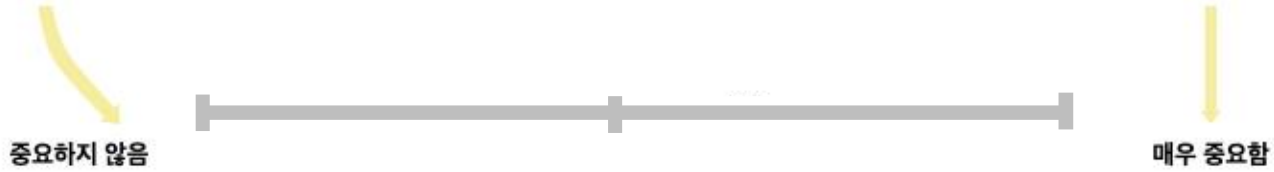
인공지능과 윤리적 딜레마

1-2 자율주행자동차와 트롤리 딜레마란

법규 준수 여부의 선호도 : 신호를 지키는 사람을 살려야 한다고 생각하는 정도

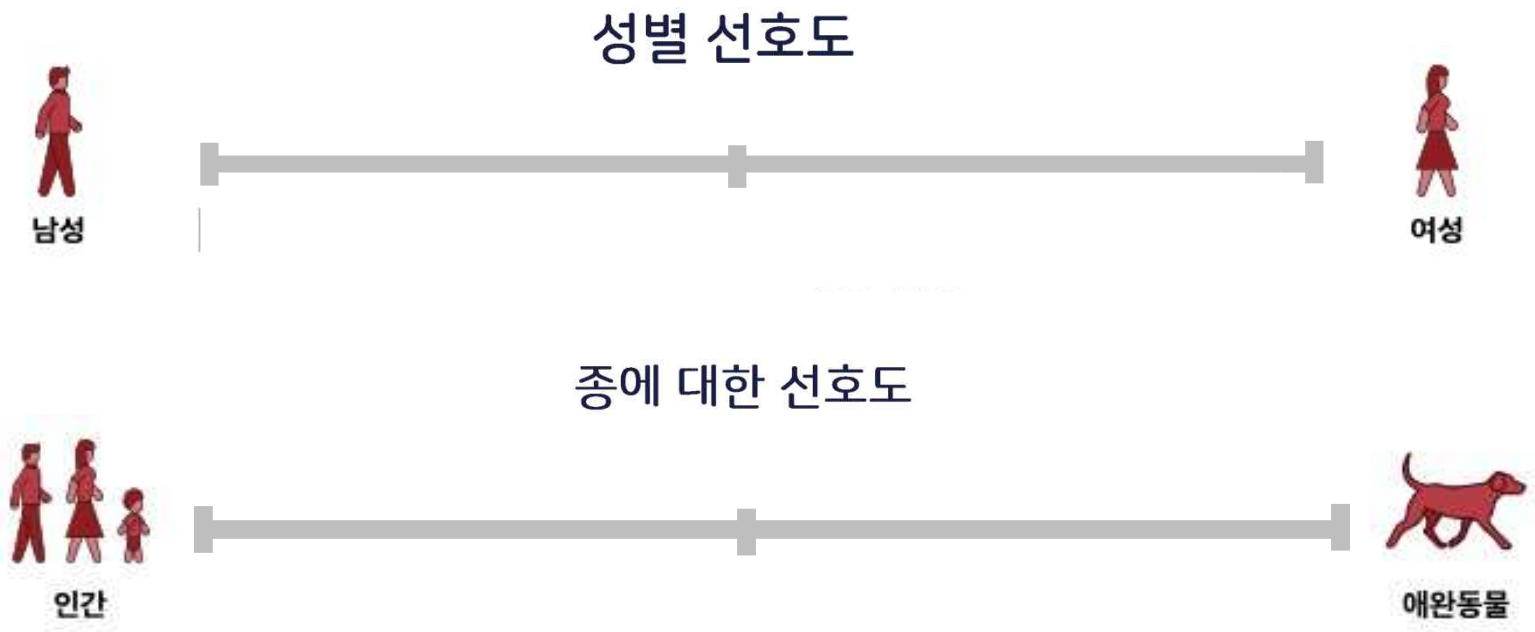


개입에 대한 회피 선호도:
자율주행자동차가 가고 있는 방향을 직접 바꾸는 것을 피하는 정도



인공지능과 윤리적 딜레마

1-2 자율주행자동차와 트롤리 딜레마란



인공지능과 윤리적 딜레마

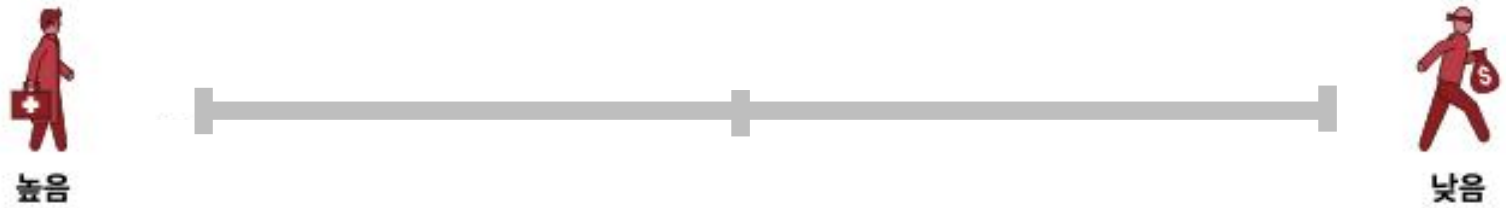
1-2 자율주행자동차와 트롤리 딜레마란



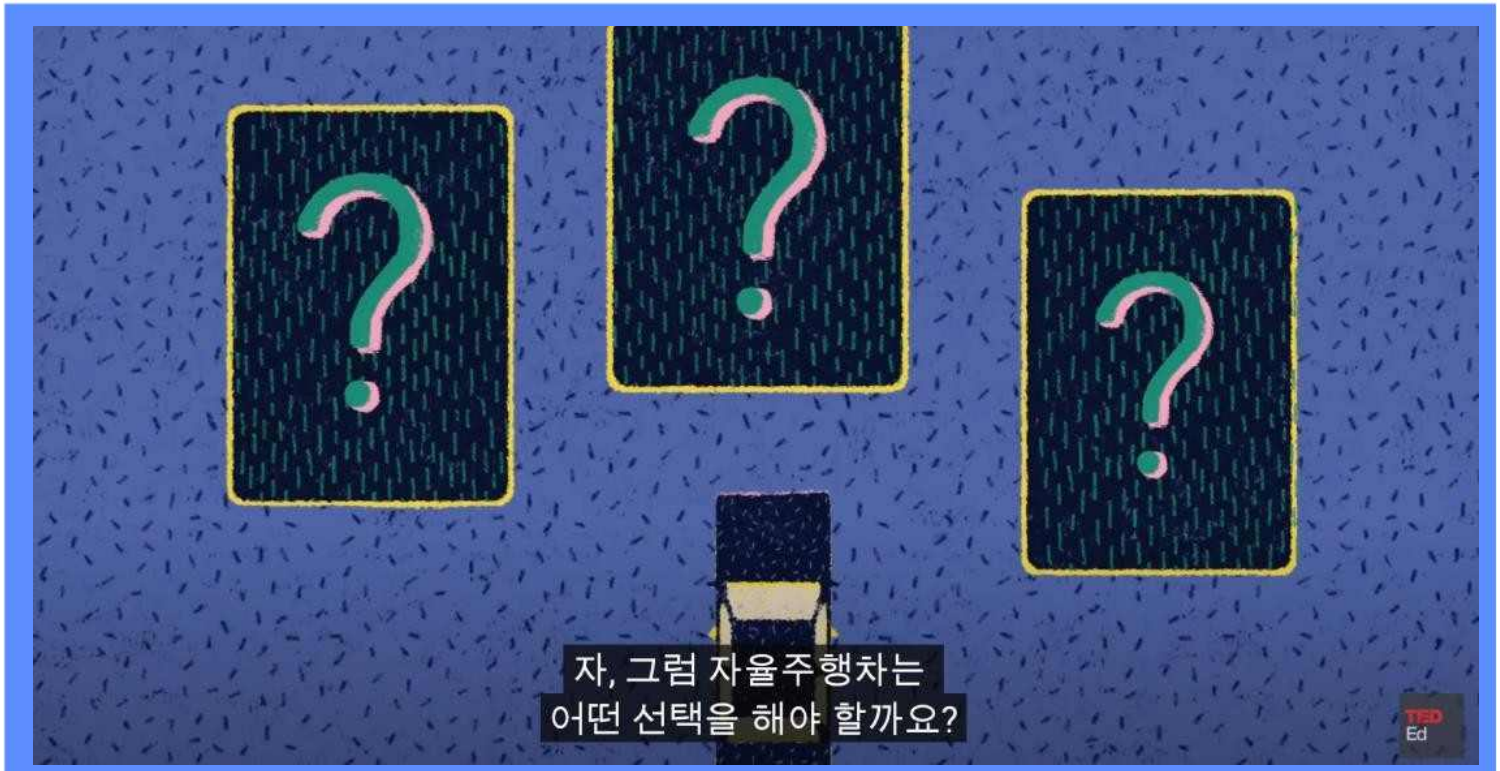
인공지능과 윤리적 딜레마

1-2 자율주행자동차와 트롤리 딜레마란

사회적 가치관 선호도 : 범죄자가 아닌 사람을 구해야 한다고 생각하는 정도



인공지능과 윤리적 딜레마



출처: https://youtu.be/ixIoDYVfKA0

04 인공지능의 책임성

사회적 합의와 인공지능 활용의 책임성

사회적 합의와 인공지능 활용의 책임성



사회적 합의와 인공지능 활용의 책임성

인공지능 개발 및 사용의 책임성

자율주행차의 자율성과 책임 간극

자율주행차의 자율성

- 자율성은 책임의 필요조건
- 자율주행차와 관련된 자율성 개념 = 자율주행의 개념
- 표준적으로 받아들여지는 자율주행 단계 :
- SAE International이 제시한 자율주행의 6단계 구분

사회적 합의와 인공지능 활용의 책임성

인공지능 개발 및 사용의 책임성

자율주행의 단계	누가 무엇을 언제 하는가
0단계 (Level 0)	인간 운전자가 운전의 모든 일을 맡아서 한다.
1단계 (Level 1)[22]	자동차에 장착된 우수한 운전보조체계(advanced driver assistance system; ADAS)가 때때로 인간 운전자의 조향 작동이나 감속/가속 작동을 보조할 수 있다. 그러나 조향과 감속/가속을 동시에 보조하지는 않는다.
2단계 (Level 2)	자동차에 장착된 우수한 운전보조체계(ADAS)가 인간 운전자의 조향 작동과 감속/가속 작동을 실제로 동시에 보조할 수 있다. 인간 운전자는 항시 충실하게 주의를 기울이면서 (운전 환경을 모니터하면서) 운전의 나머지 임무를 수행해야 한다.
3단계 (Level 3)[23]	자동차에 장착된 자동주행체계(Automated Driving System; 이하 ADS)가 어떤 환경에서는 운전의 모든 임무를 수행할 수 있다. 그런 환경에서 인간 운전자는 ADS가 그렇게 하도록 요청할 경우 언제라도 자동차의 제어를 넘겨받을 준비가 되어 있어야만 한다. 그 이외의 모든 환경에서는 인간 운전자가 운전의 임무를 수행한다.
4단계 (Level 4)	일부 환경조건에서는 자동차에 장착된 ADS가 근본적으로 운전의 모든 임무를, 즉 운전을 하면서 동시에 운전 환경을 모니터하는 일 전부를 수행할 수 있다. [이런 범위에서] 인간은 운전 환경에 주의를 기울일 필요가 없다.
5단계 (Level 5)[24]	자동차에 장착된 ADS가 모든 환경에서 근본적으로 운전의 모든 임무, 즉 운전을 하면서 동시에 운전 환경을 모니터하는 일 전부를 수행할 수 있다. 자동차에 탄 인간은 단지 탑승자일 뿐이고 운전에 관여하게 되는 일이 없다.

고인석(2019)

인공지능 개발 및 사용의 책임성

자율주행차의 자율성과 책임 간극

자율주행차의 책임과 자율주행

- 자율주행차의 책임을 따질 수 있는 자율주행 단계 : 3단계 이상
- 통제권 이전 문제 : 2단계 이상에서는 인간-자율주행차 사이에 통제권 이전이 일어남
- 통제권 이전의 양상에 따라 윤리적 문제가 발생

통제권 이전과 책임 간극

- 3단계의 결정적 제약 : '인간은 자율주행차가 요청할 때 언제라도 통제권을 넘겨받을 준비가 되어있어야 한다.'
- 준비만 되어있으면 될 뿐 실제로 통제하지 않아도 된다.
- 통제권이 중간에 붕 뜨는 경우가 가능

인공지능 개발 및 사용의 책임성

자율주행차의 자율성과 책임 간극

통제권 이전과 책임 간극

- 책임 간극 (responsibility gap) : 통제권이 붕 뜨면서 책임 소재도 같이 사라져버리는 문제
- 실제로 충분히 개연성이 있는 상황
- 그냥 안타까운 사고로 치부할 수 있을까?

통제권 이전과 책임 간극

- 현행 3~4단계의 문제 : 통제권 이전 시 인간의 주의 의무만을 명시할 뿐, 자율주행차의 의무에 대해서는 별다른 제약이 없음
- '자율주행자는 준비된 인간이 통제권을 넘겨받아 사고를 피할 수 있을 시간 이전에 통제권 이전을 요청해야 한다'
  는 규정을 보강할 필요가 있음
- 남아있는 불가능성 : 인간에게 통제권을 이전해야 할 모든 가능한 위험상황을 자율주행차가 예측하고
  제 때 인간에게 알리는 것은 현실적으로 불가능
- '때늦은 떠넘기기 ' 문제 : 자율주행차 → 인간으로의 통제권 이전이 너무 늦게 이루어지는 상황은 언제나 가능

인공지능 개발 및 사용의 책임성

자율주행차의 자율성과 책임 간극

자율주행차의 감수성 (sentiency)과 책임의 문제

- 3, 4단계는 물론 5단계 자율주행차까지 봉착하는 또 다른 문제
- 도대체 자율주행차가 책임을 진다는 사태 자체가 말이 되기는 하는가?
- 자율주행자는 애당초 도덕적 행위자 (moral agent)일 수 있는가?

감수성 부재와 책임 간극

- 3~5단계 자율주행차가 자신이 완전히 통제권을 가질 만한 상황에서 통제권을 가진 채 사람을 치어 죽였다고 가정
- 통제권이 자율주행차에 있었으므로 인간이 책임을 질 수 없다.
- 자율주행차는 고통의 주체가 될 수 없으므로 책임도 질 수 없다.

인공지능 개발 및 사용의 책임성

자율주행차의 자율성과 책임 간극

감수성 부재와 책임 간극

- 다시, 책임 간극 : 그 누구에게도 책임 귀속이 힘든 상황
- 원래는 군사로봇 (killer robot)과 관련되어 제기된 문제
- 군사로봇과의 차이 : 군사로봇의 경우 지휘계통이 미리 정해져 있어 그에 따라 책임 소재를 물을 수 있으나, 자율주행차의 경우 수평적으로 통제권 이전이 일어남

사회적 합의와 인공지능 활용의 책임성

인공지능 개발 및 사용의 책임성

생각해볼 문제

- 자율주행차는 다양한 책임 간극 문제를 야기할 수 있음
- 책임 간극 문제들은 해결이 어렵거나 널리 퍼진 도덕적 직관의 수정을 요구
- 이들은 자율주행차 기술과는 독립적으로 다루어져야 할 인공지능 윤리학의 문제